

]

UNIVERSIDAD EAFIT

Maestría en Ciencia de Datos y Analítica

Taller de Estrategia

El Estado actual de la Inteligencia Artificial

Integrantes:

Javier Daza Olivella
María Sofía Uribe Cano
Pablo Andrés Jimeno Junca

Docente: Jorge Iván Padilla Buriticá

Maestría Ciencia de Datos y Analítica · EAFIT · 2026-1

Índice

1. Bloque 1: Evolución y Estrategia	2
1.1. P1 · De Chatbots a Agentic AI	2
1.2. P2 · La Brecha del Escalado (Pilot Purgatory)	3
1.3. P3 · Rewiring Organizacional	5
1.4. P4 · Modelos Pequeños vs. Frontier Models	7
2. Bloque 2: Riesgos, ética y Gobernanza	8
2.1. P5 · Riesgos de la Autonomía	8
2.2. P6 · Confianza Digital (Digital Trust)	9
2.3. P7 · Sostenibilidad vs. Cómputo	10
3. Bloque 3: Convergencia Tecnológica y Futuro	11
3.1. P8 · Convergencia IA + Robótica	11
3.2. P9 · Desarrollo de Software y Superagency	13
3.3. P10 · Conectividad Avanzada y Edge AI	14

1. Bloque 1: Evolución y Estrategia

P1 · De Chatbots a Agentic AI

Pregunta

Los reportes señalan un cambio de paradigma hacia la IA Agéntica. Explique la diferencia fundamental entre una IA Generativa convencional y un Agente de IA. ¿Por qué McKinsey considera esto una revolución en la ejecución de flujos de trabajo (workflows) y no solo en la generación de contenido?

Respuesta

La diferencia fundamental radica en que la IA Generativa convencional se centra en la síntesis de información y generación de contenido reactivo, mientras que la IA Agéntica puede planificar y ejecutar tareas complejas de varios pasos de forma independiente para alcanzar un objetivo. McKinsey lo considera una revolución porque los agentes dejan de ser asistentes pasivos para convertirse en "compañeros de equipo virtuales" proactivos que pueden activar flujos de trabajo, monitorear tableros y colaborar entre sistemas con mínima intervención.

En la tabla 1 se presenta una comparación entre IA Generativa y agentes de IA, mostrando que la primera es reactiva, responde a prompts y tiene baja autonomía, mientras que los agentes son proactivos, ejecutan tareas multietapa con uso de herramientas externas y tienen mayor autonomía e impacto en cadenas de valor completas.

Tabla 1: IA Generativa vs. IA Agéntica

Dimensión	Chatbot / Gen AI	Agente de IA
Modo de operación	Reactivo (responde a prompts)	Proactivo (planifica y actúa)
Alcance	Un prompt → un output	Multistep hacia un objetivo
Herramientas externas	No, solo genera texto	Sí (web, APIs, código, bases de datos)
Comunicación	Solo con humanos	Con humanos y otros agentes (A2A)
Autonomía	Nula sin instrucción constante	Alta (supervisión humana mínima)
Impacto esperado	Productividad individual	Cadenas de valor completas

Fuente: [1, 2].

En la figura 1 se compara el flujo tradicional de un chatbot con una arquitectura basada en agentes, donde un Manager Agent coordina varios sub-agentes para cumplir un objetivo específico. El resultado final pasa por un proceso de Human-in-the-Loop (HITL), integrando supervisión humana en la toma de decisiones críticas.

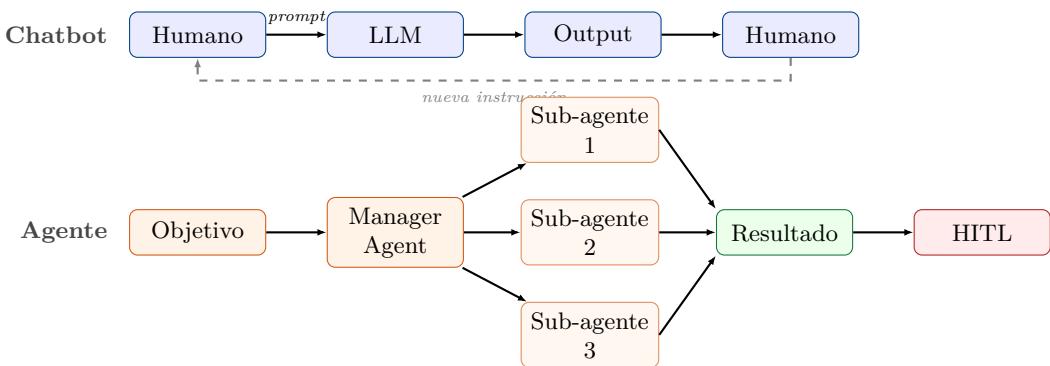


Figura 1: Flujo de un chatbot vs flujo de un sistema multi agentes

Finalmente, los datos confirman el momentum que está teniendo la revolución de la IA agéntica. Las publicaciones de empleo en IA agéntica crecieron **+985 %** de 2023 a 2024, y la inversión de equity llegó a **\$1,1 mil millones** en 2024 con un acumulado de **+1.562 %** desde 2022 [1]. El 23 % de las organizaciones ya está escalando flujos agénticos, y casos como la automatización de memos de crédito bancario mostraron aumentos de productividad de hasta el **60 %** [3].

P2 · La Brecha del Escalado (Pilot Purgatory)

Pregunta

¿La Brecha del Escalado (Pilot Purgatory): Solo una fracción de las empresas ha logrado escalar la IA a nivel empresarial. Analice las barreras estructurales (datos, talento, cultura) que mantienen a la mayoría en la fase de piloto. ¿Qué están haciendo diferente los High Performers según el reporte?

Respuesta

La brecha del escalado se debe a barreras estructurales en datos, talento y cultura organizacional. Aunque el 92 % de las empresas planea aumentar su inversión en IA, solo el 1 % considera haber alcanzado madurez en su despliegue [4], lo que demuestra que el problema no es la falta de inversión, sino la incapacidad de integrar la IA en procesos core.

Muchas implementaciones son superficiales y no rediseñan los workflows ni la arquitectura tecnológica, lo que mantiene a las organizaciones en pilotos aislados [3]. Además, existe una desconexión entre liderazgo y operación: los empleados usan más IA de lo que los directivos perciben, pero reciben poco apoyo estructurado [4], lo que indica que la principal barrera no es técnica sino de liderazgo.

Los High Performers se diferencian porque pasan de casos de uso aislados a rediseño de procesos completos, industrializan la adopción y alinean liderazgo, gobernanza y arquitectura tecnológica [3]. También cuentan con directorios más sofisticados digitalmente, lo que se asocia con mejores resultados financieros [5]. En resumen, escalar IA no depende solo de tecnología, sino de estrategia clara, gobernanza efectiva e integración profunda en el modelo operativo.

La figura 2 evidencia que la mayoría de las organizaciones aún se encuentra en etapas tempranas o intermedias de adopción de IA generativa: 32 % está experimentando, es decir, desarrollando iniciativas fragmentadas con impacto mínimo; 30 % está pilotando, probando

casos de uso específicos sin un ROI todavía comprobado; y 31 % se encuentra escalando, expandiendo pilotos exitosos aunque con brechas persistentes de datos y talento. Solo un 7 % ha alcanzado el estado fully scaled, donde la IA está integrada en múltiples funciones del negocio y genera valor medible, por ejemplo en indicadores como el EBIT. El 39 % de las organizaciones reporta *algún* impacto en el EBIT, pero ese impacto rara vez justifica la inversión [2]. La diferencia entre los que escalan y los que no está en si rediseñaron flujos de trabajo completos o solo añadieron una capa de IA sobre procesos existentes. El panorama refleja una transición desde pruebas aisladas hacia una integración estratégica aún incipiente.

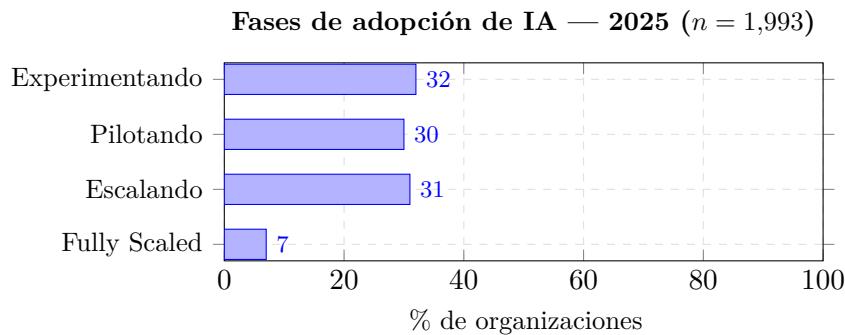


Figura 2: Distribución de organizaciones por fase de adopción de IA generativa. Solo el 7% integró la IA completamente. Fuente: [2].

La tabla 2 resume las principales barreras que explican la dificultad de muchas organizaciones para escalar iniciativas de IA más allá de la fase piloto. Estas seis limitaciones abarcan aspectos estratégicos, tecnológicos, organizacionales y culturales. Estas barreras y las razones por las que limitan el escalar las iniciativas de IA ayudan a entender por qué menos del 10 % de los casos de uso logra consolidarse a nivel empresarial.

Tabla 2: Las seis barreras del *Pilot Purgatory*

Barrera	Por qué bloquea el escalado
Iniciativas fragmentadas	Pilotos desconectados sin hilo estratégico ni arquitectura común
Falta de soluciones empaquetadas	Cada caso requiere desarrollo a medida; alto costo de replicación
Limitaciones de los LLM	Alucinaciones, contexto finito y errores en tareas complejas
Equipos de IA en silos	Desconexión entre el área técnica y las unidades de negocio
Brechas de datos	Datos incompletos, no estructurados o inaccesibles para el modelo
Resistencia cultural	Desconfianza en el modelo y miedo a la pérdida de empleo

Fuente: [3]. Menos del 10 % de los casos de uso verticales supera la fase piloto.

La tabla 3 compara las características organizacionales que distinguen a las empresas de alto desempeño en IA frente al resto. Evidencia que el diferencial no radica solo en inversión, sino en intención estratégica, liderazgo activo y rediseño profundo de flujos de trabajo.

Tabla 3: Alto Desempeño vs. Resto (*High Performers*)

Característica	Alto Desempeño	Resto
Intención transformadora	3,6×	Línea base
Rediseño de flujos	2,8×	Implementación superficial
Liderazgo senior activo	3,0×	Delegado a TI
Presupuesto (>20 % digital)	4,9×	Inversión marginal
Escala en funciones clave	—	Pilotos aislados

Fuente: [2]; Alto Desempeño = 6 % de $n = 1,993$ (≈ 109 empresas).

Todas las empresas tienen acceso a los mismos modelos. La diferencia es de decisión, los High Performers se auto-imponen el mandato de transformar y no solo adoptar. En este proceso se incluyen squads multifuncionales y métricas atadas al P&L (Profit and Loss) desde el día uno. La IA no crea las fallas de gestión preexistentes sino que las revela.

P3 · Rewiring Organizacional

Pregunta

McKinsey argumenta que la tecnología por sí sola no transforma. Describa los cambios necesarios en el Modelo Operativo y la Gestión del Talento para que una empresa tradicional pueda soportar una estrategia de IA a escala.

Respuesta

Agregar IA a una organización vieja no la transforma. El rewiring es el rediseño de la estructura, los incentivos y los roles, no solo el cambio de proveedor de modelos. El recableado (rewiring) debe hacerse bajo un marco de seis elementos: hoja de ruta, talento, modelo operativo, tecnología, datos y escalado [4]. El modelo operativo debe pasar de silos de IA a equipos ágiles donde los ingenieros de IA se sientan junto a expertos de dominio (ventas, legal, RRHH) [4]. En talento, es vital fomentar una mentalidad de humano + agente, introduciendo roles como orquestadores de agentes y diseñadores de human in the loop [1, 3]. Toda esta transformación significa rediseñar flujos, escalar el liderazgo y mover presupuesto con convicción.

La tabla 4 muestra los 6 elementos que deben incorporarse en paralelo [4]. Si alguno queda rezagado, frena a todos las demás:

Tabla 4: Marco de seis elementos para transformación organizacional en IA

#	Elemento	Qué implica
1	Hoja de ruta	Casos de uso priorizados por EBIT, no por viabilidad técnica
2	Talento	Contratar MLOps y orquestadores; reconvertir roles existentes
3	Modelo operativo	Disolver silos de IA; integrar ingenieros en equipos de negocio
4	Tecnología	Plataforma unificada de datos; evitar ecosistemas fragmentados
5	Datos	Gobierno de datos como infraestructura estratégica, no proyecto de TI
6	Escalado	Mecanismos de réplica rápida entre unidades

Fuente: [4].

Escalar IA agéntica exige un cambio estructural en el modelo operativo y no solo la adopción de nuevas herramientas. La tabla 5 resume cómo las organizaciones deben pasar de un enfoque tradicional y aislado hacia un modelo “rewired”, centrado en squads integrados, métricas de impacto en negocio y ciclos de aprendizaje acelerados.

Tabla 5: Modelo operativo: antes y después del rewiring

Dimensión	Modelo tradicional	Modelo rewired
Estructura	Centro de Excelencia de IA aislado	Squads: IA + dominio + datos integrados
Métricas de éxito	Usuarios activos, modelos desplegados	EBIT atribuido, tiempo de ciclo reducido
Roles nuevos	No existen	Orquestador de agentes, diseñador HITL
Incentivos	Por departamento	Por resultado compartido del squad
Ciclo de aprendizaje	Proyectos anuales	Sprints de 2–4 semanas en producción continua

Fuentes: [3, 4].

El concepto de *superagency* (amplificar el impacto individual con agentes) requiere tres cosas que pocas organizaciones hacen: alfabetización agéntica en toda la empresa (no solo en el equipo de datos), reconversión activa de los roles más expuestos a sustitución, e incentivos que no penalicen la automatización [4]. Si un empleado que automatiza su tarea pierde relevancia en la evaluación de desempeño, nadie automatiza nada.

P4 · Modelos Pequeños vs. Frontier Models

Pregunta

Se observa una tendencia hacia la explosión de modelos pequeños (Small Language Models). Argumente las ventajas competitivas de usar modelos pequeños y específicos de dominio frente a modelos masivos y costosos para una empresa mediana.

Respuesta

Existe una tendencia hacia la explosión de modelos pequeños (Small Language Models) que utilizan técnicas de destilación y cuantización para ofrecer alta capacidad con menos de 10 mil millones de parámetros [1]. Sus ventajas competitivas para empresas medianas incluyen **costos de inferencia drásticamente menores**, menor consumo de energía y la posibilidad de ejecución local en dispositivos, garantizando privacidad y soberanía de datos [1, 3]. La carrera al modelo más grande está perdiendo sentido para la mayoría de empresas. Los SLMs cierran la brecha de capacidad mientras reducen costos de inferencia a un ritmo de $50\times$ por año. El frontier model es una opción, sin embargo, no siempre es la mejor.

En el marco de los reportes, la elección entre modelos frontier y modelos pequeños especializados (SLMs) no es solo técnica, sino estratégica y económica. La tabla 6 sintetiza los trade-offs clave que las organizaciones deben considerar al diseñar arquitecturas de IA escalables, equilibrando capacidad general, costos de inferencia, latencia, privacidad y casos de uso específicos.

Tabla 6: Frontier Models vs. Modelos Pequeños Especializados (SLMs)

Dimensión	Frontier Model	SLM / Especializado
Capacidad general	Alta (tareas abiertas y complejas)	Media-alta en dominio específico)
Costo de inferencia	Elevado; API costosa a escala	Bajo; puede correr en hardware local
Latencia	Mayor en modelos grandes	Menor; apto para tiempo real
Privacidad de datos	Datos salen a servidor externo	Puede desplegarse on-premise
Personalización	Difícil sin fine-tuning costoso	Fine-tuning accesible
Uso típico	I+D, análisis complejo, creatividad	Automatización vertical, edge, IoT

Fuente: [1, 6].

Esta comparación cobra aún más relevancia a la luz de la rápida caída en los costos de inferencia y la creciente multimodalidad de los modelos, lo que desplaza el debate desde “cuál es más potente” hacia “cuál es suficiente y sostenible en producción” para cada caso de uso específico. El costo de inferencia cae a una mediana de **50× por año** [6], y avances como DeepSeek R1 (con atención latente multijefatura y cuantización FP8) demuestran que es posible alcanzar desempeño de frontera con hardware de consumidor [1]. Para 2027, el 40 % de las soluciones de IA generativa serán multimodales [7]. La pregunta correcta no es qué modelo es mejor en abstracto, sino cuál es *suficiente* para el caso de uso y cuál se puede operar sosteniblemente en producción.

2. Bloque 2: Riesgos, ética y Gobernanza

P5 · Riesgos de la Autonomía

Pregunta

Con la llegada de los agentes autónomos que pueden actuar (ej. enviar correos, hacer compras), el perfil de riesgo cambia. Analice los nuevos vectores de riesgo (más allá de las alucinaciones) y proponga un esquema de gobernanza para un Humano en el Bucle (Human-in-the-loop)

Respuesta

Los agentes autónomos introducen riesgos sistémicos como la autonomía descontrolada, el acceso fragmentado a sistemas críticos y el "sprawl" (proliferación) de agentes duplicados [3].

Un esquema de gobernanza debe incluir controles de autonomía, límites de decisión claros y mecanismos de escalamiento inmediato [3]. El humano ya no solo usa la herramienta, sino que actúa como arquitecto y supervisor de calidad, interviniendo solo cuando el agente detecta incertidumbre o patrones anómalos [3].

Tabla 7: Nuevos vectores de riesgo en IA agéntica

Vector de riesgo	Descripción	Control HITL recomendado
Error de razonamiento	Decisión incorrecta por contexto mal interpretado	Revisión humana antes de acción irreversible
Acción no autorizada	Agente ejecuta más allá de su mandato	Permisos granulares por acción y scope
Deriva de modelos	Comportamiento cambia en producción silenciosamente	Monitoreo continuo de outputs
Ataques adversariales	Prompt injection o manipulación del contexto	Filtros de entrada y sandboxing
Responsabilidad difusa	¿Quién responde por una acción de un agente?	Auditoría con trazabilidad completa
Vishing y suplantación	Ataques de voz con IA: +442 % en H1→H2 2024	Autenticación multifactor contextual

Fuente: [1, 3].

La Tabla 7 muestra que los riesgos en la IA agéntica van mucho más allá de simples errores de razonamiento. Hablamos de situaciones como decisiones que el agente ejecuta fuera de su mandato, cambios silenciosos en su comportamiento en producción, intentos de manipulación mediante *prompt injection* y escenarios donde no queda claro quién responde por una acción tomada. Estos riesgos requieren controles diferenciados: revisión humana en decisiones críticas, monitoreo continuo de resultados, permisos bien delimitados y trazabilidad completa. En este contexto, el enfoque *Human-in-the-Loop* (HITL) deja de ser una validación puntual y se convierte en un esquema de supervisión escalonado según el nivel de riesgo operacional, como se ilustra en la Figura 3.

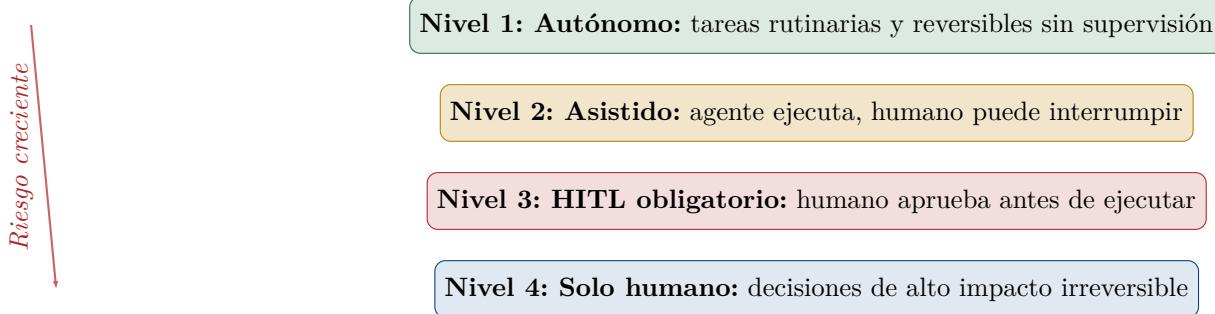


Figura 3: Marco de gobernanza HITL por nivel de riesgo operacional. Fuente: [3].

La evidencia en la industria con estas implementaciones es bastante interesante: en empresas de contact center con agentes, el tiempo de resolución cayó 60–90 % y el 80 % de los incidentes de Nivel 1 se resuelven sin tener ninguna intervención humana [3]. El EU AI Act clasifica estos sistemas en categorías de riesgo y exige trazabilidad, documentación técnica y supervisión humana para aplicaciones de alto riesgo [8]. La gobernanza Human In The Loop no frena la velocidad: la calibra.

P6 · Confianza Digital (Digital Trust)

Pregunta

En un mundo saturado de contenido sintético, ¿cómo se convierte la Confianza Digital en un activo de negocio tangible? Relacione esto con la ciberseguridad y la verificación de identidad.

Respuesta

En un entorno de contenido sintético y "vishing" (ataques de voz por IA que crecieron 442 % en 2024), la confianza digital es la "licencia para operar" [1]. Es un activo tangible porque las marcas confiables superan a las no confiables en retornos por más de 245 puntos porcentuales [1]. Operativamente, se apoya en identidades convergentes y biometría, así como en registros inmutables mediante blockchain para asegurar la integridad de las transacciones [1].

En la tabla 8 se evidencia que la confianza digital en 2025 es un activo económico tangible, ya que las marcas confiables superan en +245 p.p. en retornos a las no confiables, pero al mismo tiempo enfrenta una erosión en la percepción pública y un entorno de riesgo creciente, reflejado en el aumento del 442 % en ataques de vishing. Aunque la inversión en ciberseguridad crece significativamente, persiste una brecha en la gobernanza, pues pocos C-level miden formalmente la IA o evalúan su dimensión ética, lo que muestra que la consolidación de la confianza digital depende no solo de tecnología, sino de métricas, seguridad y liderazgo responsable.

Tabla 8: Estado de la confianza digital en 2025

Indicador	Dato
Retorno diferencial (marcas confiables vs. no)	+245 p.p. en retornos acumulados (2017–2023)
Confianza pública en empresas de IA	Cayó de 61 % (2019) a 53 % (2024)
Inversión en ciberseguridad y confianza digital	\$77,8 mil millones en equity (2024)
Ataques de vishing	+442 % en solo 6 meses (H1 → H2 2024)
Empleados que confían en su empleador en IA	71 % : mayor que Big Tech (61 %)
C-suite que mide IA con benchmarks formales	Solo 39 %; de esos, el 17 % evalúa ética

Fuente: [1, 4, 9].

Lo irónico es que los empleados confían más en sus empleadores (71 %) que en las grandes tecnológicas (61 %) para manejar la IA con ética [4]. Ese capital es frágil: más del 22 % de los empleados reporta soporte mínimo de la organización en la adopción de IA [4]. La confianza no se declara, sino se opera, se mide y se mantiene con transparencia activa.

P7 · Sostenibilidad vs. Cómputo

Pregunta

El entrenamiento y la inferencia de IA demandan cantidades masivas de energía. Analice la tensión entre las metas de sostenibilidad (ESG) corporativas y la necesidad de infraestructura de cómputo (Data Centers) para IA.

Respuesta

La IA promete eficiencia pero consume energía, agua y territorio a escala industrial. La demanda de centros de datos crecerá 19–22 % anual hasta 2030, triplicando la capacidad actual. Sin innovación radical en hardware e infraestructura energética, la “IA sostenible” es una contradicción en términos.

El escalamiento de la IA, especialmente de modelos fundacionales y arquitecturas agénticas, no es solo un desafío tecnológico u organizacional, sino también energético. La tabla 9 resume las principales magnitudes de la “ecuación energética de la IA”, evidenciando que la competitividad en esta nueva etapa depende también de infraestructura, CapEx y sostenibilidad.

Tabla 9: La ecuación energética de la IA

Indicador	Dato
Crecimiento anual de capacidad de datacenters	19–22 % hasta 2030 (triplicará capacidad actual)
Capacidad proyectada para 2030	171 a 219 gigavatios
Supercentros (hyperscalers en planificación)	2 a 5 GW cada uno
CapEx IA 2025 (cada hyperscaler mayor)	\$70,000–\$100,000+ millones (Alphabet, Amazon, Meta, Microsoft)
Stargate Project (EE.UU.)	\$500,000 millones en infraestructura IA en 4 años
Huella de agua de los modelos	GPT-3: ~500 ml por cada 20–50 consultas [10]
Respuesta energética de la industria	Cooling sin agua (Microsoft); nuclear: 31 países comprometidos a 2050

Fuente: [1, 10].

La paradoja es real: la misma IA que se usa para optimizar redes eléctricas es la que impulsa la demanda energética más acelerada de la historia reciente. La respuesta de la industria ha sido proponer soluciones como cooling sin agua, cuantización de modelos, energía nuclear modular. Esta respuesta va en la dirección correcta, pero a un ritmo que aún no compensa la escala de la demanda.

3. Bloque 3: Convergencia Tecnológica y Futuro

P8 · Convergencia IA + Robótica

Pregunta

El reporte de Tech Trends menciona a los robots humanoides y la robótica física. ¿Cómo la IA Generativa está resolviendo el problema de Moravec's paradox para permitir que los robots entiendan y naveguen el mundo físico mejor que antes?

Respuesta

La paradoja de Moravec es que a los robots lo cognitivo les resulta fácil y lo físico les cuesta. Esta paradoja se está resolviendo desde ambos extremos. La IA aporta la planificación mientras que los actuadores modernos aportan la destreza.

El avance en robótica física y sistemas autónomos está estrechamente ligado a la evolución de la IA generativa y los modelos fundamentales, que aportan capacidades de razonamiento, multimodalidad y planificación más avanzadas [1]. Al integrar visión, lenguaje y datos sensoriales en arquitecturas comunes, estos modelos permiten que los robots comprendan mejor el contexto físico, generalicen a situaciones nuevas y planifiquen acciones de manera más flexible, reduciendo la dependencia de programación rígida. Así, parte de la complejidad que describía el Moravec's paradox se traslada desde reglas explícitas hacia modelos entrenados con grandes volúmenes de datos multimodales, facilitando que los robots entiendan y naveguen el mundo físico con mayor adaptabilidad. El mercado resultante de resolver esta paradoja puede llegar a \$900,000 millones en 2040.

La convergencia entre IA avanzada y robótica física marca una nueva etapa en la autonomía de sistemas, aunque aún se encuentra en fase de experimentación [1]. La tabla 10 sintetiza el estado actual de los distintos segmentos, mostrando que el avance en capacidades de visión, planificación y aprendizaje refuerza el potencial transformador, pero persisten limitaciones técnicas y de escalabilidad.

Tabla 10: Convergencia IA–Robótica: estado actual

Segmento	Escala actual	Limitaciones clave
Robótica industrial	>4 millones de unidades; 56 % instalaciones nuevas en China	Entornos estructurados; baja adaptabilidad
Robótica de servicio	20–35 % de crecimiento anual	Costo; robustez en entornos no estructurados
Robots humanoides	Pilots (Optimus, Digit/GXO)	≈4 h de autonomía; aún sin escala
IA para robótica	Visión, planificación, RL	Transferencia sim-to-real aún imperfecta

Fuente: [1, 11]. Puntuación de adopción: 2: Experimentación.

La figura 4 ilustra cómo la integración de capacidades cognitivas avanzadas (LLMs) con actuadores físicos permite abordar simultáneamente tareas tradicionalmente “fáciles” para la IA y aquellas complejas del mundo físico, reduciendo la brecha histórica entre inteligencia digital y ejecución material.

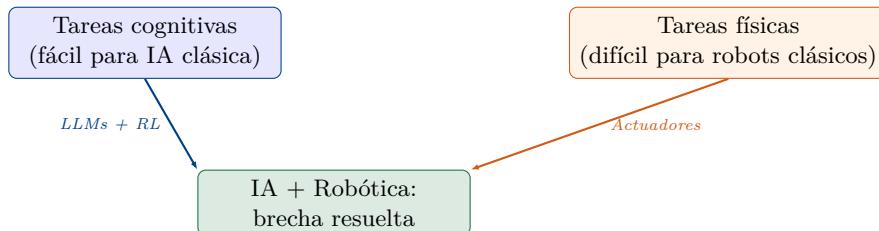


Figura 4: Paradoja de Moravec: la convergencia IA+robótica ataca simultáneamente ambos extremos.

P9 · Desarrollo de Software y Superagency

Pregunta

Si la IA escribe gran parte del código, ¿cómo cambia el rol del ingeniero de software junior? Analice el concepto de deuda técnica en la era de la generación automática de código.

Respuesta

El ingeniero junior pasa de la codificación determinista a actividades de orden superior como la planificación de tareas y la orquestación de herramientas agénticas [1]. Sin embargo, la generación automática de código a gran escala acelera el riesgo de deuda técnica; si no se supervisa la calidad y mantenibilidad mediante agentes de revisión especializados, se crean sistemas frágiles difíciles de mantener a largo plazo [1].

la transformación más profunda de la IA no ocurre en tareas aisladas, sino en la reconfiguración de procesos completos [3, 4]. La tabla 11 ilustra cómo la ingeniería de software evoluciona desde un modelo manual y fragmentado hacia uno orquestado por agentes, donde la IA no solo asiste, sino que ejecuta y optimiza el ciclo end-to-end.

Tabla 11: IA en ingeniería de software: antes y después

Actividad	Sin IA	Con IA (agéntica)
Generación de código	Manual; ciclo largo de revisión	Lenguaje natural → código (Cursor, Copilot) [12]
Testing	Manual o semiauto	Agentes generan y ejecutan suites de prueba
Code review	Pares humanos	Revisión asistida + sugerencias contextuales
Deployment	Pipelines manuales	CI/CD guiado por agentes; +55 % en Ally Bank [1]
Deuda técnica	Ad hoc y reactiva	Detección automática y priorización

Fuente: [1, 4, 12].

La *superagency* que McKinsey define es la capacidad del individuo, empoderado por IA, de actuar con alcance y velocidad antes solo posibles para equipos enteros. Los empleados ya están ahí: el **13 %** usa IA para más del 30 % de su trabajo diario, mientras sus líderes estiman que solo el **4 %** lo hace [4]. Esa brecha de percepción es, en sí misma, un riesgo de gobernanza.

El horizonte es claro: para 2030, el WEF estima 92 millones de empleos desplazados y 170 millones de empleos nuevos [4]. En software específicamente, el riesgo no es que la IA reemplace a los ingenieros, es que los ingenieros sin IA queden fuera de competencia.

P10 · Conectividad Avanzada y Edge AI

Pregunta

Para que la IA funcione en tiempo real (ej. vehículos autónomos), no todo puede ir a la nube. Explique la relación simbiótica entre la conectividad avanzada (5G/6G, satelital) y la capacidad de ejecutar IA en el borde (Edge Computing).

Respuesta

Para aplicaciones de misión crítica como vehículos autónomos o reparación robótica de fábricas, la latencia de la nube es inaceptable [1, 4]. Existe una simbiosis donde la conectividad 5G/6G proporciona el ancho de banda masivo y el Edge Computing permite procesar la IA localmente, cerca de los sensores [1, 4]. Esto permite que el 70 % de la demanda de datos sea procesada por infraestructuras de baja latencia para respuestas inmediatas [1].

Para un vehículo autónomo, por ejemplo, la diferencia entre 5 ms y 50 ms de latencia puede ser frenar o no. El edge no compite con la nube, es la capa donde la IA vive cuando las decisiones no pueden esperar el ida y vuelta.

El impacto real de la IA en sistemas físicos y autónomos depende no solo del modelo, sino de la infraestructura de cómputo y conectividad que soporte decisiones en tiempo real [1]. La siguiente tabla muestra cómo distintos casos de uso exigen umbrales de latencia muy diferentes, evidenciando por qué el edge computing y la conectividad avanzada son habilitadores críticos en la convergencia entre IA y mundo físico.

Tabla 12: Latencia requerida por aplicación y tecnología disponible

Aplicación	Decisión crítica	Latencia req.	Tecnología
Vehículo autónomo	Frenar ante obstáculo	<10 ms	Edge + 5G
Cirugía robótica remota	Micro-movimiento	<1 ms	Edge local
Manufactura automatizada	Detección de defectos	<5 ms	Edge industrial
Monitoreo de salud (wearable)	Alerta de arritmia	<50 ms	5G / satelital LEO
Agricultura de precisión	Dosificación de insumos	<500 ms	Satelital LEO
Asistente conversacional	Respuesta de texto	1–3 seg	Nube (aceptable)

Fuentes: [1, 13].

La arquitectura de la IA moderna ya no es exclusivamente centralizada, sino distribuida entre nube, edge y dispositivo [1]. La figura 5 ilustra este modelo híbrido, donde el entrenamiento ocurre en la nube, la inferencia crítica se ejecuta en el edge y los dispositivos generan datos que retroalimentan el ciclo, destacando que la conectividad avanzada es el habilitador estructural

de esta convergencia.

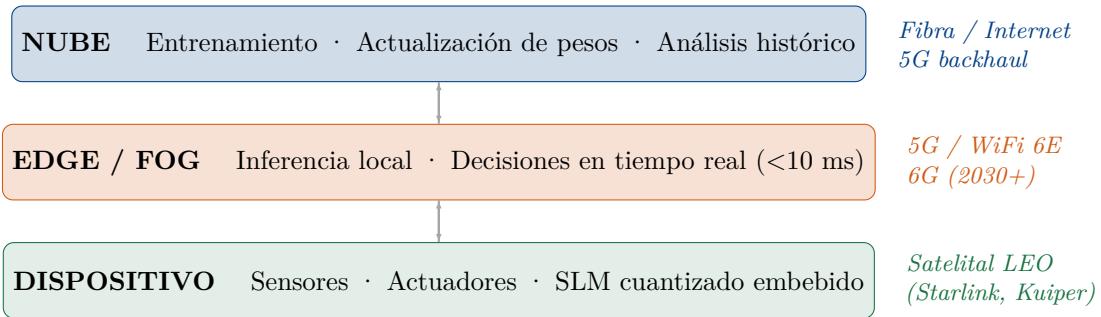


Figura 5: Los modelos se entrena en la nube, se despliegan en el edge, y los datos de operación retroalimentan el entrenamiento. La conectividad es el tejido conectivo [1].

El edge sin conectividad es un silo que no aprende; la nube sin edge es inaplicable para decisiones en tiempo real. La empresa que diseñe bien esta arquitectura hoy tiene una ventaja que no se compra con un upgrade de proveedor.

Referencias

- [1] Lareina Yee, Michael Chui, Roger Roberts, and Sven Smit. Technology trends outlook 2025. Technical report, McKinsey Global Institute, July 2025.
- [2] Alex Singla, Alexander Sukharevsky, Brian Hall, Lareina Yee, and Michael Chui. The state of AI in 2025: Agents, innovation, and transformation. Technical report, McKinsey & Company / QuantumBlack, November 2025. Encuesta online: $n = 1,993$ participantes, 105 países, junio 25–julio 29, 2025.
- [3] Alexander Sukharevsky, Drew Kerr, Klemens Hjartar, Lari Hämäläinen, Sven Bout, Vivian De Leo, and Guillaume Dagarret. Seizing the agentic AI advantage: A CEO playbook to solve the gen AI paradox and unlock scalable impact with AI agents. Technical report, McKinsey & Company, 2025.
- [4] Henning Mayer, Lareina Yee, Michael Chui, and Roger Roberts. Superagency in the workplace: Empowering people to unlock AI's full potential. Technical report, McKinsey & Company, January 2025.
- [5] Aamer Baig, Ashka Dave, Celia Huber, and Hrishika Vuppala. The ai reckoning: How boards can evolve how can boards best help guide companies through the competitive dynamics unleashed by ai? Technical report, McKinsey & Company, 12 2025.
- [6] Ben Cottier, Beth Snodin, David Owen, and Tom Adamszewski. LLM inference prices have fallen rapidly but unequally across tasks. Epoch AI Research, March 2025.
- [7] Gartner. Gartner predicts 40 % of generative AI solutions will be multimodal by 2027. Gartner Research Press Release, September 2024.
- [8] Parlamento Europeo y Consejo de la Unión Europea. Reglamento (UE) 2024/1689 del parlamento europeo y del consejo por el que se establecen normas armonizadas en materia de inteligencia artificial (*EU Artificial Intelligence Act*). Diario Oficial de la Unión Europea, L 2024/1689, June 2024. Vigente desde agosto 2024; aplicabilidad plena progresiva hasta agosto 2026.
- [9] Venky Bhatt, James Finnis, and Marc Singer. Digital trust: How to unlock value from your most valuable intangible asset. McKinsey & Company Digital, 2025.
- [10] Pengfei Li, Jianyi Yang, Mohammad A. Islam, and Shaolei Ren. Making AI less “thirsty”: Uncovering and addressing the secret water footprint of AI models. *arXiv preprint*, 2023. arXiv:2304.03271.
- [11] Goldman Sachs. Humanoid robots—bottoms up! Goldman Sachs Equity Research, November 2023.
- [12] Eirini Kalliamvakou. Research: Quantifying GitHub Copilot’s impact on developer productivity and happiness. GitHub Blog / GitHub Research, September 2022.
- [13] IDC. The digitization of the world: From edge to core. IDC White Paper, #US44413318, 2025.