Taller de Entrenamiento: Aprendizaje Supervisado

Fundamentos, Experimentación y Despliegue de Modelos

Curso: Inteligencia Artificial ECA&I - (Posgrado)
Docente: Jorge Iván Padilla-Buriticá
Universidad EAFIT - Periodo 2026-1

Objetivo del Taller

Este taller busca consolidar los fundamentos del aprendizaje supervisado mediante una evaluación conceptual rigurosa y la aplicación práctica en problemas de regresión y clasificación. Los estudiantes deberán demostrar habilidades en el flujo completo de Ciencia de Datos: desde el preprocesamiento hasta el despliegue de modelos interactivos.

1 Parte 01: Evaluación Conceptual (Quiz)

Instrucciones

Seleccione la respuesta correcta para cada una de las siguientes 20 preguntas. Justifique brevemente su elección (máximo 3 líneas) basándose en la teoría estadística y computacional.

1. En un modelo de regresión lineal, si el valor del estadístico R^2 es 0.95, pero el error en el conjunto de prueba es significativamente mayor que en el de entrenamiento, estamos ante:

   a) Underfitting (Subajuste).
   b) Overfitting (Sobreajuste).
   c) Sesgo (Bias) alto.
   d) Error irreducible.

2. La principal diferencia entre el Aprendizaje Supervisado y el No Supervisado es:

   a) El uso de algoritmos de optimización.
   b) La presencia de una variable objetivo (*label*) conocida.
   c) La cantidad de datos necesarios.
   d) La capacidad de procesar imágenes.

3. Al evaluar un clasificador para detectar enfermedades raras (clases desbalanceadas), ¿qué métrica es más informativa que el *Accuracy*?

   a) Error Cuadrático Medio (MSE).

   b) Coeficiente de Determinación.
   c) F1-Score o Precision-Recall AUC.
   d) Desviación estándar de los residuos.

4. En validación cruzada (*K-Fold Cross Validation*), si $K = N$ (donde N es el número de muestras), el método se conoce como:

   a) Bootstrap.
   b) Stratified K-Fold.
   c) Leave-One-Out Cross-Validation (LOOCV).
   d) Validación por *hold-out*.

5. La función de pérdida "Log-Loss" (o Entropía Cruzada) es comúnmente utilizada para:

   a) Regresión lineal multivariada.
   b) Clasificación probabilística.
   c) Clustering de K-medias.
   d) Reducción de dimensionalidad PCA.

6. Respecto al *Trade-off* entre Sesgo (Bias) y Varianza:

   a) Modelos complejos tienden a tener alto sesgo y baja varianza.
   b) El error total se minimiza aumentando la varianza indefinidamente.
   c) Modelos muy simples suelen presentar alto sesgo y baja varianza.
   d) No existe relación entre la complejidad y el error.

7. ¿Para qué sirve la técnica de Regularización L2 (Ridge) en regresión?

   a) Para eliminar variables haciendo sus coeficientes exactamente cero.
   b) Para penalizar la magnitud de los coeficientes y evitar el sobreajuste.
   c) Para aumentar la complejidad del modelo.
   d) Para normalizar los datos entre 0 y 1.

8. El área bajo la curva ROC (AUC-ROC) mide:

   a) La precisión exacta en el punto de corte 0.5.
   b) La capacidad del modelo para distinguir clases independientemente del umbral.
   c) El error promedio de las predicciones continuas.
   d) La correlación entre las características de entrada.

9. En clasificación, una matriz de confusión permite identificar específicamente:

   a) Los hiperparámetros óptimos.
   b) El tiempo de ejecución del entrenamiento.
   c) Falsos Positivos, Falsos Negativos, Verdaderos Positivos y Negativos.
   d) La importancia de las características.

10. El fenómeno de la "Maldición de la Dimensionalidad" implica que:

   a) A más dimensiones, más fácil es encontrar patrones.
   b) El volumen del espacio crece exponencialmente, haciendo los datos dispersos.

   c) El rendimiento siempre mejora con más variables.
   d) Los datos se vuelven más densos.

11. ¿Cuál es la principal ventaja de utilizar *Stochastic Gradient Descent* (SGD) sobre el *Batch Gradient Descent*?

   a) Garantiza alcanzar siempre el mínimo global.
   b) Es computacionalmente más eficiente en conjuntos de datos masivos.
   c) Reduce la varianza de las actualizaciones del modelo.
   d) No requiere escalar las características.

12. El uso de *StandardScaler* (Z-score normalization) es crítico en algoritmos basados en distancias como:

   a) Árboles de Decisión.
   b) K-Nearest Neighbors (KNN) y SVM.
   c) Naive Bayes.
   d) Random Forest.

13. La Regularización L1 (Lasso) se diferencia de L2 (Ridge) principalmente porque:

   a) L1 siempre produce mejores predicciones.
   b) L1 puede realizar selección de características al llevar coeficientes a cero.
   c) L2 es más propensa al *overfitting*.
   d) No existe diferencia matemática real.

14. ¿Qué indica una curva de aprendizaje donde tanto el error de entrenamiento como el de validación son altos y cercanos entre sí?

   a) El modelo sufre de alta varianza (Overfitting).
   b) El modelo sufre de alto sesgo (Underfitting).
   c) El modelo ha alcanzado la convergencia óptima.
   d) Se necesitan menos datos de entrenamiento.

15. En el contexto de *Random Forest*, el concepto de "OOB Error" (Out-of-Bag) se utiliza para:

   a) Medir el tiempo de poda de los árboles.
   b) Estimar el error de generalización sin necesidad de un conjunto de validación externo.
   c) Calcular la profundidad máxima de cada árbol.
   d) Normalizar los pesos de los clasificadores débiles.

16. ¿Cuál es el propósito del parámetro de "Kernel" en una *Support Vector Machine* (SVM)?

   a) Reducir el número de vectores de soporte.
   b) Proyectar datos a un espacio de mayor dimensión para buscar separabilidad lineal.
   c) Acelerar el proceso de gradiente descendente.
   d) Limpiar los valores atípicos del dataset.

17. En un problema de clasificación multiclase, la estrategia "One-vs-Rest" (OvR):

   a) Entrena un único modelo para todas las clases simultáneamente.
   b) Entrena un clasificador binario por cada clase frente a todas las demás.
   c) Compara cada par posible de clases individualmente.
   d) Solo funciona con redes neuronales profundas.

18. La métrica MAE (Mean Absolute Error) es preferible sobre MSE (Mean Squared Error) cuando:
   a) Se desea penalizar fuertemente los errores grandes (outliers).
   b) Se busca una métrica más robusta y menos sensible a valores atípicos.
   c) La variable objetivo sigue una distribución normal perfecta.
   d) No hay diferencia, ambas miden lo mismo.

19. ¿Qué técnica ayuda a combatir el *Data Leakage* (Fuga de datos)?
   a) Realizar el escalamiento de datos (*fit*) solo sobre el conjunto de entrenamiento.
   b) Usar todas las variables disponibles en el dataset original sin filtrar.
   c) Entrenar el modelo con los datos de prueba incluidos.
   d) Imputar valores faltantes usando la media de todo el dataset antes de dividir.

20. El algoritmo XGBoost se basa en la técnica de:
   a) Bagging (muestreo con reemplazo).
   b) Boosting (entrenamiento secuencial para corregir errores previos).
   c) Stacking (combinación de modelos heterogéneos).
   d) Clustering jerárquico.

2 Parte 02: Componente Experimental (Lab)

Selección de Datos

Para este taller, se recomienda trabajar con los siguientes datasets clásicos de Kaggle/UCI. Sin embargo, los equipos tienen libertad de elegir **cualquier otro conjunto de datos**, siempre que cuente con **más de 1,000 muestras**.

- **Recomendado Regresión:** *Medical Cost Personal Datasets* (Seguros médicos).
- **Recomendado Clasificación:** *Telco Customer Churn* (Fuga de clientes).

2.1 Flujo de Trabajo Requerido

Para ambos ejercicios (Regresión y Clasificación), el reporte debe documentar:

1. **Diferentes Modelos:** Emplear por lo menos 3 modelos diferentes para cada tarea (Reg.Lineal, Polinomial, Logística, K-regression, K-NN, SVM, RF, DT, etc.).
2. **Análisis Exploratorio (EDA):** Identificación de correlaciones, valores faltantes y sesgos.
3. **Preprocesamiento:** Limpieza, codificación (*One-Hot*/*Label*) y escalamiento.
4. **Ingeniería de Características:** Selección de variables basada en importancia o métodos estadísticos.
5. **Entrenamiento y Ajuste:** Búsqueda de hiperparámetros (*GridSearch* o *RandomSearch*).
6. **Validación Robusta:** Uso obligatorio de *Cross-Validation* y reporte de métricas en *Test set*.

3 Parte 03: Despliegue e Interfaz (Dashboard)

Reto de Despliegue

El modelo final no debe ser solo un archivo `.pkl`. Debe ser una herramienta interactiva donde un usuario pueda ingresar datos y obtener una respuesta inmediata.

Utilice herramientas como **Streamlit**, **Lovable** o **v0.dev** para crear un *dashboard* dinámico. La aplicación debe permitir cargar un archivo CSV para predicciones por lote o usar un formulario para predicciones individuales.

3.1 Checklist de verificación

Asegúrese de cumplir con todos los puntos antes de subir su enlace de GitHub:

- ☐ Repositorio de GitHub organizado con carpetas `/data`, `/notebooks` y `/app`.
- ☐ Notebooks de Python (`.ipynb`) comentados y con conclusiones por sección.
- ☐ Archivo `requirements.txt` para replicar el entorno.
- ☐ Enlace funcional a la aplicación (ej. Streamlit Cloud).
- ☐ El Dashboard debe incluir al menos un gráfico de *Feature Importance*.
- ☐ Evidencia de pruebas de usuario (ejemplos de predicciones exitosas).

4 Parte 04: Entregable

Cada Equipo enviará vía correo las evidencias de la implementación y las respuestas conceptuales, tienen libertad para hacerlo todo en plataforma, o notebook, o una tabla. Solamente deben entregar evidencia de las respuestas y/o enlace a la plataforma donde implementaron la solución. Fecha de límite de entrega: 10 de marzo de 2026.

"In God we trust, all others must bring data." - W. Edwards Deming