PARCIAL – NLP y LLMs Avanzado

Sintonización de Parámetros, Métricas de Similitud
y Evaluación de Modelos de Lenguaje

Curso: Inteligencia Artificial ECA&I – Posgrado
Docente: Jorge Iván Padilla-Buriticá
Universidad: EAFIT – Periodo 2026-1
Integrantes: María Sofía Uribe, Javier Daza, Pablo Jimeno

PARTE 01 – Evaluación Conceptual (Quiz Teórico) 25 puntos

Pregunta 1 — Similitud coseno vs. distancia euclidiana (5 pts)

Explique la diferencia entre similitud coseno y distancia euclidiana como métricas de comparación entre embeddings. ¿En qué escenarios de NLP preferiría una sobre la otra?

Definiciones formales

Dado dos vectores $\mathbf{A}, \mathbf{B} \in \mathbb{R}^d$:

$$\text{similitud coseno:} \quad \cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \, \|\mathbf{B}\|} = \frac{\sum_{i=1}^{d} A_i B_i}{\sqrt{\sum_i A_i^2} \, \sqrt{\sum_i B_i^2}} \in [-1, 1] \tag{1}$$

$$\text{distancia euclidiana:} \quad d(\mathbf{A}, \mathbf{B}) = \|\mathbf{A} - \mathbf{B}\|_2 = \sqrt{\sum_{i=1}^{d} (A_i - B_i)^2} \in [0, +\infty) \tag{2}$$

Diferencia conceptual clave

La distancia euclidiana es la longitud de la línea recta más corta entre dos puntos en un espacio euclidiano. Si visualizamos dos embeddings como puntos, esta métrica calcula qué tan lejos están físicamente uno del otro. Matemáticamente, es sensible a la magnitud (si un vector es mucho más largo que otro, aunque apunten en la misma dirección, la distancia euclidiana será grande). En cambio, la similitud coseno mide el coseno del ángulo que forman dos vectores que parten desde el origen. Esta métrica normaliza la longitud, lo que significa que es invariante a la magnitud. Si dos documentos tratan sobre el mismo tema pero uno es mucho más largo que el otro, sus vectores resultantes tendrán magnitudes distintas pero una orientación similar, resultando en una similitud coseno alta.

Los modelos de embeddings de oraciones (p.ej. SBERT, OpenAI `ada`) codifican el significado semántico en la *dirección* del vector, no en su norma. Dos oraciones

con el mismo contenido semántico pero con diferentes frecuencias léxicas pueden producir vectores con normas muy distintas pero ángulos casi idénticos.

Equivalencia tras normalización L2: ¿Cuándo son equivalentes ambas métricas?

Si ambos vectores están normalizados ($\|\mathbf{A}\| = \|\mathbf{B}\| = 1$), se verifica la siguiente equivalencia:

$$\|\mathbf{A} - \mathbf{B}\|^2 = \|\mathbf{A}\|^2 + \|\mathbf{B}\|^2 - 2\,\mathbf{A} \cdot \mathbf{B} = 2 - 2\cos(\theta)$$

Por lo tanto, en espacios L2-normalizados, ambas métricas producen el mismo ordenamiento y son intercambiables. Esto es importante porque cuando los embeddings han sido normalizados previamente a una longitud unitaria, minimizar la distancia euclidiana es matemáticamente equivalente a maximizar la similitud coseno.

Consideraciones para ambientes productivos

Algunos índices como HNSW/FAISS soportan el producto punto o la similitud coseno, están optimizados de forma nativa para la distancia euclidiana ($L2$). Al normalizar los vectores a una magnitud de uno, la relación matemática se vuelve lineal: minimizar la distancia euclidiana es equivalente a maximizar la similitud coseno. Esto permite aprovechar la eficiencia computacional de los algoritmos de búsqueda de vecinos más cercanos (ANN) diseñados para $L2$, obteniendo los beneficios semánticos de la orientación pero con la velocidad de procesamiento de un índice euclidiano.

¿Cuándo usar cada una en NLP?

Métrica	Escenario preferido
Similitud coseno	Búsqueda semántica, recuperación de documentos (RAG), clustering de oraciones, deduplicación, detección de paráfrasis. El significado está en la dirección del embedding, no en su norma.
Distancia euclidiana	Cuando la magnitud del vector codifica información relevante (p.ej. en ciertos espacios de búsqueda visual con embeddings de imágenes, un vector con mayor magnitud puede indicar una presencia más fuerte de un patrón específico, algo que la similitud coseno ignoraría al reducir todo a una dirección en la esfera unitaria.) o cuando, habiendo normalizado previamente, se requiere compatibilidad con índices que están optimizados de forma nativa para la distancia euclidiana ($L2$) como HNSW/FAISS

Pregunta 2 — Token probability mass y parámetros de muestreo (5 pts)

¿Qué es el fenómeno de token probability mass y cómo los parámetros temperatura, top-p y top-k redistribuyen dicha masa en la distribución Softmax de salida de un LLM?

Definición: token probability mass

El fenómeno de token probability mass se refiere a la distribución de probabilidad total, que siempre suma 1.0 (o 100 %), repartida entre todos los tokens posibles del vocabulario de un modelo de lenguaje en un paso de predicción determinado. En cada paso de generación, un LLM produce un vector (serie de puntuaciones crudas denominadas) $\mathbf{z} \in \mathbb{R}^{|V|}$ (uno por token del vocabulario V). Al aplicar la función Softmax sobre estos logits, se transforman en una distribución de probabilidad donde cada token recibe una fracción de esa "masa". Recordemos que la función Softmax que se define como:

$$\sigma(\mathbf{z})_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

$$\mathrm{P}(\mathrm{t}_i \mid \text{contexto}) = \frac{e^{z_i}}{\sum_{j=1}^{|V|} e^{z_j}}$$

El fenómeno de *token probability mass* describe el hecho de que, para predicciones de alta confianza, casi toda la masa de probabilidad se concentra en muy pocos tokens (a veces solo 3–10 de un vocabulario de ≈100 000 tokens). Por ejemplo, si un token tiene una probabilidad de 0.9, acapara casi toda la masa, dejando el resto para miles de otros tokens en lo que se conoce como la çola"de la distribución. Los parámetros de muestreo actúan sobre esta masa antes de seleccionar el siguiente token.

Temperatura T

La temperatura es el primer mecanismo de redistribución y actúa directamente sobre los logits antes de la función Softmax. Matemáticamente, divide cada logit por un valor T y se define formalmente como:

$$\mathrm{P}_T(t_i) = \frac{e^{\frac{z_i}{T}}}{\sum_j e^{\frac{z_j}{T}}}$$

- $T \to 0$: distribución colapsa al argmax (decodificación greedy, respuestas deterministas).
- $T < 1$: se amplifica la diferencia entre los logits: el token más probable aumenta su dominio y "succiona"la masa de probabilidad de los demás, haciendo que el modelo sea más determinista y enfocado.
- $T = 1$: distribución original sin modificación.
- $T > 1$: suaviza las diferencias, aplanando la distribución y repartiendo la masa de forma más equitativa entre tokens que originalmente tenían probabilidades bajas. Esto aumenta la diversidad y la aleatoriedad, permitiendo que el

modelo explore opciones menos evidentes pero también aumento el riesgo de incoherencia o alucinaciones.

Top-k

El parámetro Top-K realiza una redistribución mediante el truncamiento drástico de la masa. En lugar de permitir que cualquier token del vocabulario sea seleccionado, el modelo identifica los k tokens con mayor probabilidad y descarta por completo al resto. La masa de probabilidad que correspondía a los tokens eliminados se redistribuye proporcionalmente entre los k seleccionados, asegurando que la suma vuelva a ser 1.0.

Tras aplicar la temperatura, se retienen únicamente los k tokens con mayor probabilidad y se renormaliza la masa sobre ese subconjunto. Este método de truncamiento es simple, eficiente y es útil para evitar que el modelo elija tokens altamente improbables que podrían arruinar la coherencia del texto. Sin embargo, puede ser un filtro rígido que no se adapta a la forma de la distribución. Por ejemplo, en distribuciones muy planas, $k = 50$ puede incluir tokens irrelevantes.

Top-p (nucleus sampling)

El Top-P, también conocido como Nucleus Sampling, ofrece una redistribución dinámica basada en la masa acumulada. En lugar de elegir un número fijo de tokens, el modelo selecciona el conjunto más pequeño de tokens cuya probabilidad sumada alcance el umbral p (por ejemplo, 0.9). Si el modelo está muy seguro de su siguiente palabra, el "núcleo"podría contener solo uno o dos tokens; si está inseguro, el núcleo se expande para incluir muchos más. Al igual que en Top-K, toda la masa de probabilidad fuera de este núcleo se elimina y la masa restante se normaliza. Este enfoque permite que el modelo sea creativo cuando hay múltiples opciones válidas, pero se mantenga estrictamente lógico cuando solo hay una respuesta correcta evidente Se define el conjunto de tokens más probables cuya probabilidad acumulada supera el umbral p:

$$\mathrm{V}_p = \mathrm{argmin}_{S \subseteq V} \left\{ |S| : \sum_{t_i \in S} P(t_i) \geq p \right\}$$

Solo los tokens de V_p participan en el muestreo (el resto se enmascara a $-\infty$ antes de renormalizar). A diferencia de top-k, el tamaño efectivo del vocabulario se adapta dinámicamente a la distribución: distribuciones muy concentradas producen conjuntos V_p pequeños; distribuciones planas producen conjuntos más amplios.

Pregunta 3 — BLEU, ROUGE-L y BERTScore (5 pts)

Defina con sus palabras BLEU, ROUGE-L y BERTScore. ¿Por qué BERTScore captura semántica que BLEU no puede detectar?

BLEU (Bilingual Evaluation Understudy)

BLEU es una métrica diseñada originalmente para la traducción automática que mide la precisión de n-gramas. En términos sencillos, cuenta cuántas palabras o secuencias de palabras (unigramas, bigramas, etc.) del texto candidato aparecen exactamente igual en uno o varios textos de referencia. Para evitar que el modelo

haga trampa generando frases extremadamente cortas pero precisas, incluye un çastigo por brevedad"(*brevity penalty*). Es una métrica puramente sintáctica: si usas un sinónimo perfecto que no está en la referencia, BLEU te penalizará porque no hay una coincidencia exacta de caracteres. La definición matemática es

$$\text{BLEU} = \text{BP} \cdot \exp\Big(\sum_{n=1}^{N} w_n \ln p_n\Big), \quad BP = \text{mín}\big(1,\ e^{1-r/c}\big)$$

donde p_n es la precisión de n-gramas de orden n, r la longitud de referencia, c la del candidato, y $w_n = 1/N$ pesos uniformes. BLEU es completamente **léxico**, es decir, no reconoce sinónimos ni paráfrasis.

ROUGE-L (Recall-Oriented Understudy for Gisting Evaluation)

ROUGE-L se basa en la secuencia común más larga (LCS) entre el texto generado y la referencia. A diferencia de BLEU, que se enfoca en la precisión, ROUGE pone el peso en el recall": qué tanto del contenido importante de la referencia lograste incluir en tu salida. Al buscar la secuencia más larga de palabras que aparecen en el mismo orden relativo (aunque no sean contiguas), captura mejor la estructura de la oración que los n-gramas rígidos, pero sigue dependiendo de que las palabras coincidan literalmente. La definición matemática es:

$$\text{F}_{LCS} = \frac{(1+\beta^2)\, P_{LCS}\, R_{LCS}}{R_{LCS}+\beta^2\, P_{LCS}}, \quad P_{LCS} = \frac{\text{LCS}(X,Y)}{|Y|}, \quad R_{LCS} = \frac{\text{LCS}(X,Y)}{|X|}$$

ROUGE-L se utiliza principalmente en tareas de resumen ya que captura coherencia estructural y orden sin requerir coincidencia de n-gramas exactos consecutivos. Al igual que BLEU, es léxica (no reconoce sinónimos ni paráfrasis).

BERTScore

BERTScore utiliza embeddings contextuales de modelos como BERT para comparar la similitud entre la generación y la referencia. En lugar de buscar coincidencias exactas de tokens, calcula la similitud del coseno entre los vectores de cada palabra en ambas frases. Esto permite que la métrica entienda que dos palabras diferentes pueden significar lo mismo en un contexto dado. Además, utiliza un alineamiento greedy para emparejar cada palabra de la generación con la palabra más similar de la referencia, sumando esas puntuaciones para obtener un resultado final de precisión, recall y F1.

Para cada token de referencia x_i encuentra la similitud coseno máxima con cualquier token del candidato $\hat{x}_j$, y viceversa:

$$\text{R}_{BERT} = \frac{1}{|x|} \sum_{x_i \in x} \text{máx}_{\hat{x}_j \in \hat{x}} \cos(\mathbf{x}_i, \hat{\mathbf{x}}_j), \quad P_{BERT} = \frac{1}{|\hat{x}|} \sum_{\hat{x}_j \in \hat{x}} \text{máx}_{x_i \in x} \cos(\hat{\mathbf{x}}_j, \mathbf{x}_i)$$

F_{BERT} es la media armónica de P_{BERT} y R_{BERT}.

¿Por qué BERTScore captura semántica que BLEU no puede?

BLEU asigna solapamiento 0 entre "*automóvil*" y "*carro*" porque son tokens distintos. En el espacio de embeddings de BERT, ambas palabras aparecen en contextos casi idénticos durante el preentrenamiento, por lo que sus representaciones vectoriales son muy cercanas (cos $\approx$ 0,90). BERTScore detecta esta similitud semántica; BLEU es ciego a ella.

Característica	BLEU	ROUGE-L	BERTScore
Captura sinónimos	No	No	Sí
Sensible al orden	Parcial	Sí (LCS)	Parcial
Costo computacional	Bajo	Bajo	Alto
Interpretabilidad	Alta	Alta	Media

Pregunta 4 — Fine-tuning supervisado (SFT) vs. LoRA (5 pts)

¿Qué diferencia conceptual existe entre el fine-tuning supervisado (SFT) y el método LoRA para adaptar un LLM a un dominio específico? ¿Cuál es la ventaja en términos de parámetros entrenables?

La diferencia conceptual reside en cómo se modifican los pesos originales del modelo para aprender una nueva tarea. En el SFT tradicional, se realiza un reentrenamiento completo (Full Fine-tuning), lo que significa que el gradiente se calcula para cada uno de los parámetros del modelo y todos ellos se actualizan. LoRA, por el contrario, parte de la premisa de que el cambio en los pesos durante la adaptación tiene una "dimensión intrínseca baja". En lugar de tocar los pesos originales del modelo (que se mantienen congelados), LoRA inyecta pares de matrices de bajo rango en las capas de atención del transformador. Conceptualmente, es como añadir una capa delgada o un "parche.externo que aprende la especialización, mientras el conocimiento general del modelo base permanece intacto. El resultado final es la suma de los pesos originales congelados y el producto de estas nuevas matrices pequeñas.

La ventaja en términos de parámetros entrenables es el principal motivo de la popularidad de LoRA. Mientras que en un SFT tradicional debes entrenar y almacenar el 100 % de los parámetros (por ejemplo, 7 mil millones para un modelo Llama-7B), con LoRA normalmente solo se entrena entre el **0.01 % y el 2 %** de la red. Esto reduce drásticamente los requisitos de memoria VRAM, permitiendo que ingenieros adapten modelos enormes en hardware de consumo. Además, al terminar el entrenamiento, no es necesario guardar una copia completa del modelo de varios gigabytes; solo se necesitan guardar los .ªdaptadores"(las matrices pequeñas), que suelen ocupar apenas unos pocos megabytes.

Esta eficiencia permite que un mismo modelo base pueda cargar y descargar diferentes adaptadores LoRA de forma dinámica según la tarea (por ejemplo, uno para soporte médico y otro para análisis legal) sin tener que reiniciar o recargar gigabytes de memoria.

Fine-tuning supervisado (SFT)

El SFT actualiza **todos** los parámetros del modelo base W_0 mediante retropropagación sobre un conjunto de datos (x_i, y_i) de pares instrucción-respuesta. El resultado modifica irreversiblemente los pesos del modelo base.

LoRA (Low-Rank Adaptation)

LoRA congela los pesos originales $W_0 \in \mathbb{R}^{d\times k}$ e inyecta una *descomposición de bajo rango* aditiva:

$$\mathrm{W} = \mathrm{W}_0 + \Delta W = W_0 + \tfrac{\alpha}{r}\,\mathbf{AB}, \quad \mathbf{A} \in \mathbb{R}^{d\times r},\ \mathbf{B} \in \mathbb{R}^{r\times k},\ r \ll \min(d,k)$$

Solo **A** y **B** se entrenan. **B** se inicializa en cero para que $\Delta W = 0$ al comienzo del entrenamiento.

Ventajas adicionales de LoRA

- Los adaptadores (**A**, **B**) se pueden intercambiar sin recargar el modelo base (múltiples dominios con un solo modelo).
- **QLoRA** extiende LoRA cuantizando el modelo base a 4 bits, habilitando fine-tuning de modelos de 7B en una sola GPU de 24 GB.
- Menor riesgo de catastrofic forgetting al no modificar W_0.

Pregunta 5 — LLM-as-a-Judge (5 pts)

Explique el concepto de LLM-as-a-Judge. ¿Cuáles son sus ventajas frente a la evaluación humana y cuáles sus principales sesgos conocidos (position bias, verbosity bias)?

Definición del concepto

El concepto de LLM-as-a-Judge se refiere a la práctica de utilizar un modelo de lenguaje capaz para evaluar de forma automática la calidad, precisión o seguridad de las respuestas generadas por otros modelos de IA. En lugar de depender exclusivamente de métricas deterministas tradicionales como BLEU o ROUGE, que comparan cadenas de texto de forma literal y a menudo fallan en capturar la semántica, este enfoque utiliza la capacidad de razonamiento del "modelo juez"para calificar una respuesta basándose en una rúbrica específica y una salida esperada o comparándola con una respuesta de referencia.

Ventajas frente a la evaluación humana

Ventaja	Descripción
Escalabilidad	Permite evaluar miles de respuestas por hora sin costo de mano de obra especializada.
Consistencia	El mismo modelo con la misma temperatura produce evaluaciones reproducibles, eliminando la variabilidad inter-anotador.
Economía	Costo por evaluación más bajo que el de un anotador experto.
Disponibilidad	Operación 24/7, sin fatiga ni sesgo por contexto social.
Criterios actualizables	El prompt de evaluación puede modificarse instantáneamente para incorporar nuevos criterios.

Sesgos conocidos

A pesar de las ventajas que presenta, este método introduce sesgos cognitivos propios del modelo que pueden distorsionar los resultados, entre ellos resaltamos:

***1. Position bias* (sesgo de posición):** En evaluaciones de tipo “A vs. B”, el LLM tiende a favorecer la respuesta presentada en **primera posición** (o última,

dependiendo del modelo), con independencia de la calidad real. *Mitigación:* Para realizar evaluaciones cruzadas intercambiando el orden de las respuestas.

***2. Verbosity bias* (sesgo de extensión):** El LLM juez los LLM tienden a calificar mejor las respuestas más largas, asociando erróneamente la extensión del texto con una mayor calidad o completitud, incluso si la respuesta corta es más directa y correcta. Este sesgo es análogo al *waffle* que puede explotar el reward model en RLHF. *Mitigación:* incluir instrucciones explícitas en el prompt del juez sobre la preferencia por concisión.

***3.Self-enhancement/self-preference bias* (sesgo de auto-favorecimiento):** Los LLMs tienden a calificar más alto las salidas producidas por modelos de la misma familia o arquitectura y que por tanto, producen respuestas que se parecen a su propio estilo de escritura,